

Автор [admin](#) 8 дней назад
Обновлено [l.bobko.work](#) 1 день назад

Отображается для всех... 2

Поднять проект Parser + Парсинг отзывов Яндекс.Карт + start_date

yandex

- OBR

Проект
Обратка
- M

Приоритет
Medium
- LB

Исполнитель
l.bobko.work
- O

Столбец
Open
- P

Задача
Product
- F

Тип задачи
Feature
- O

Статус
Open
- P

Эпик
Парсинг данных и обработка

Дата готовности
16 апр. 2026

Доски
Обратка

Назначение

Модуль сбора публичных отзывов с Яндекс.Карт по карточкам компаний/филиалов, выбранным пользователем. География — РФ. Целевой объём — 500–15 000 отзывов за запуск.

Первый шаг: поднять Parser - сервис

Прежде чем собирать отзывы с Яндекса — нужно развернуть сам сервис, в котором будут жить все модули сбора (Яндекс, Google, 2GIS). Это общий каркас:

принимает задачу на сбор, запускает нужный модуль, сохраняет результат, отдаёт статус. Без него ни один источник не заработает.

Система собирает отзывы из нескольких источников: 2GIS, Яндекс.Карты, Google Maps (РФ). Каждый источник требует своего метода сбора.

Зафиксировано:

- Как минимум один, вероятно несколько источников используют **Playwright** (браузерная автоматизация со скроллом и парсингом DOM)
- Обход антибот-защиты обязателен: браузерный пул, прокси-ротация, stealth-плагины, rate limiting — общая инфраструктура для всех источников
- Конкретный метод сбора и стратегия обхода per source — **открытый вопрос** (требуется research-задач)
- Переход на сторонние сервисы (Apify, Outscraper) возможен позже без смены архитектуры

Второй шаг: Реализация сбора отзывов с Яндекс.Карт

Процесс работы

1 → Поиск карточки компании

Пользователь вводит название компании и город. Система ищет организации в Яндекс.Картах, возвращает список (название, адрес, рейтинг, кол-во отзывов). Пользователь выбирает одну или несколько точек. Для каждой сохраняется `businessId` — уникальный идентификатор организации в Яндекс.Картах.

2 → Сбор отзывов

По `businessId` модуль собирает отзывы. Три режима: разовый сбор, инкрементальный (live-мониторинг), ручное обновление.

Режим	Что собирает	Когда использует ся
Разовый сб ор	Все отзывы за указанный период (диа пазон дат или «с самого начала»)	Первый анализ, р учной запуск
Инкремент альный	Только новые отзывы после даты пос леднего успешного обновления	Live-мониторинг по расписанию
Ручное обн овление	То же, что инкрементальный, но запу щено пользователем досрочно	Кнопка «Обновить вручную»

Критическое ограничение: Яндекс.Карты отдают **максимум 600 отзывов на одну организацию** — это жёсткий лимит платформы, обойти нельзя никаким методом. Для большинства бизнесов в РФ этого достаточно, но для крупных сетей (Сбербанк, Пятёрочка) данные будут неполными.

Частичный workaround: собирать с двумя разными сортировками (`by_time` и `by_relevance_org`) — выборки пересекаются, но не полностью, что позволяет захватить больше уникальных отзывов.

3 → Что сохраняем по каждому отзыву

Поле	Формат	Примечание
Текст отзыва	string	Полный текст
Дата публикации и	Unix timestamp → ISO 8601	Яндекс отдаёт в Unix
Источник	enum	Константа <code>yandex_maps</code>
Оценка	int 1–5	Звёздный рейтинг
ID филиала	string	<code>businessId</code> карточки
ID отзыва	string	Идентификатор от Яндекса
Имя автора	string	Идентификация
ID автора	string	Профиль в Яндексе
Язык отзыва	string	Для pipeline перевода

Бонус от Яндекса — встроенная аналитика (если доступна):

Эти данные можно использовать как дополнительный сигнал для собственного анализа тональности и тем.

4 → Проверка квоты

Менее 5–10 отзывов → анализ не запускается, пользователь получает сообщение.

5 → Обработка ошибок

Та же схема: `retry` 3 раза, логирование, статус «частично», уведомление пользователю и администратору.

Варианты технической реализации

У Яндекс.Карт **нет официального API для отзывов**. Но есть недокументированный внутренний endpoint, который использует сам сайт.

Предложенные варианты, но в рамках реализации на них можно не опираться.

Вариант	Суть	Скорость (5K отзывов)	Нюанс
А — Внутренний API	Endpoint <code>fetchReviews</code> — JSON, 50 от	5–15 мин	Быстро, но endpoint нестабилен — Яндекс переи


```
5         n = (33 * n) ^ ord(char)
        return n & 0xFFFFFFFF
```

Обнаружен язык Python

Без правильного `s` запрос вернёт ошибку. Алгоритм был реверс-инженерен сообществом, но Яндекс может его сменить.

Известные ограничения

- **600 отзывов** — жёсткий потолок на организацию, не обходится
- Внутренний API нестабилен — Яндекс периодически меняет параметры и ломает парсеры
- `csrfToken` привязан к сессии — нельзя переиспользовать между разными IP
- Дата отдаётся в Unix timestamp — нужна конвертация в ISO 8601

Сбор отзывов начиная с определённой даты (`start_date`)

Для работы live-мониторинга нужно уметь собирать не все отзывы с карточки, а только новые — начиная с конкретной даты.

Зачем: когда мониторинг включён, система периодически проверяет карточку на новые отзывы. Каждый раз собирать всё с нуля — долго и бессмысленно. Система запоминает дату последнего успешного сбора и передаёт её как `start_date` — «собери только то, что появилось после этой даты».

Как это работает:

1. При первом анализе — собираем всё за выбранный период
2. Система фиксирует дату последнего успешного обновления
3. При следующем цикле мониторинга — передаём эту дату как `start_date`
4. Плагин Яндекс.Карт собирает отзывы с сортировкой `by_time` и останавливается, когда доходит до отзывов старше `start_date`

Что учесть: Яндекс отдаёт отзывы страницами по 50 штук. При сортировке `by_time` новые идут первыми — парсер листает страницы, пока не встретит отзыв старше `start_date`, после чего останавливается. Это экономит время: вместо 600 отзывов за 5–15 минут — может хватить одной-двух страниц за секунды.